

Disciplina: FACOM31704 - Metodologia Científica em Computação e Informática

Professor: Prof. Dr. Rafael Dias Araújo

Estudante: Leandro Marques Gontijo Jersé

Orientador(a): Prof. Dr. Bruno Augusto Nassif Travencolo

Tipo de trabalho: Projeto de Pesquisa Tradicional

Entrega 2 (E2) - Visão geral sobre a fundamentação teórica

1 RASCUNHO DA FUNDAMENTAÇÃO TEÓRICA

Este capítulo reúne os conceitos necessários para compreender a análise e a predição de trajetórias de espermatozoides em vídeos microscópicos. O domínio biomédico é apresentado por meio da análise seminal assistida por computador e dos parâmetros de motilidade. Em seguida, são discutidas as etapas computacionais que transformam quadros de vídeo em trajetórias: processamento e detecção de objetos, rastreamento multiobjeto, estimação de fluxo óptico e predição temporal. Por fim, são descritos os conjuntos de dados e as métricas que permitem avaliar cada etapa separadamente. Essa organização acompanha a dependência entre os conceitos sem confundir suas funções: detectar significa localizar células em um quadro; rastrear significa preservar suas identidades ao longo dos quadros; estimar fluxo significa descrever movimento aparente na imagem; e prever significa estimar posições que ainda não foram observadas.

1.1 Análise seminal assistida por computador e motilidade espermática

A análise seminal é empregada em contextos clínicos e de pesquisa para examinar características do sêmen e dos espermatozoides. Entre as variáveis avaliadas estão concentração, contagem total, morfologia, vitalidade e motilidade. A sexta edição do manual da Organização Mundial da Saúde sistematiza procedimentos para obtenção de resultados comparáveis e ressalta a necessidade de controle de qualidade no exame ([World Health Organization, 2021](#)). A motilidade descreve o movimento dos espermatozoides e é classificada, na avaliação básica, em progressiva, não progressiva e imóvel. A primeira categoria corresponde ao deslocamento ativo para a frente, em linha aproximadamente reta ou em trajetória ampla; a segunda reúne movimentos sem progressão efetiva; e a terceira indica ausência de movimento ([World Health Organization, 2021](#); [HAUGEN et al., 2019](#)).

Os sistemas conhecidos como *Computer-Aided Sperm Analysis* (CASA) combinam microscopia, aquisição digital de vídeo e algoritmos de processamento para tornar essa avaliação quantitativa. Em vez de resumir a amostra apenas pela inspeção visual, um sistema CASA localiza cabeças de espermatozoides, associa observações da mesma célula e calcula grandezas cinemáticas a partir das coordenadas registradas no tempo. O desenvolvimento desses sistemas ganhou força a partir da difusão de câmeras digitais e computadores em laboratórios de andrologia, enquanto as recomendações sucessivas da OMS, iniciadas em 1980, buscaram padronizar procedimentos que antes dependiam fortemente da experiência

do avaliador ([World Health Organization, 2021](#)). A automação, contudo, não elimina a necessidade de padronização: taxa de quadros, ampliação, profundidade da câmara, contraste e regras de classificação influenciam diretamente os valores calculados.

Considere uma trajetória bidimensional formada pelos centroides $\mathbf{p}_t = (x_t, y_t)$, observados em intervalos constantes Δt . Para uma trajetória com T posições, a velocidade curvilínea (VCL) corresponde ao comprimento acumulado do caminho dividido pelo tempo, enquanto a velocidade em linha reta (VSL) considera somente a distância entre a primeira e a última posição:

$$\text{VCL} = \frac{\sum_{t=1}^{T-1} \|\mathbf{p}_{t+1} - \mathbf{p}_t\|_2}{(T-1)\Delta t}, \quad (1.1)$$

$$\text{VSL} = \frac{\|\mathbf{p}_T - \mathbf{p}_1\|_2}{(T-1)\Delta t}. \quad (1.2)$$

A velocidade do percurso médio (VAP) é calculada ao longo de uma versão suavizada da trajetória. A linearidade (LIN) compara o deslocamento líquido com o caminho curvilíneo, usualmente por $\text{LIN} = 100 \text{ VSL} / \text{VCL}$. Essas medidas distinguem uma célula que percorre grande distância de forma sinuosa de outra que obtém deslocamento líquido semelhante por um caminho mais direto ([World Health Organization, 2021](#)).

Os avanços recentes em CASA deslocam parte da análise de regras manuais para modelos treinados com dados anotados. O VISEM reuniu vídeos microscópicos, resultados de análise seminal e atributos biológicos de 85 participantes, criando uma base multimodal para investigações computacionais ([HAUGEN et al., 2019](#)). Sua extensão VISEM-Tracking acrescentou caixas delimitadoras e identificadores persistentes, o que permite estudar detecção, rastreamento e cinemática em sequências mais longas ([THAMBAWITA et al., 2023](#)). Esses avanços não transformam automaticamente uma saída algorítmica em resultado clínico. Para que velocidades sejam expressas em $\mu\text{m/s}$, por exemplo, é necessário conhecer a escala espacial da imagem e a taxa de quadros; sem essa calibração, o resultado permanece em pixels por segundo. Assim, o presente trabalho utiliza o contexto CASA como domínio de aplicação e adota as trajetórias como objeto computacional de estudo, sem propor diagnóstico médico.

1.2 Processamento de imagens e detecção de espermatozoides

Uma imagem digital pode ser representada por uma função discreta de intensidade ou por múltiplos canais de cor. Em vídeos microscópicos, o processamento inicial busca realçar a separação entre as cabeças dos espermatozoides e o fundo. Conversão para tons de cinza, filtragem de ruído, normalização de contraste, limiarização e operações morfológicas são exemplos de transformações que antecedem a detecção. A segmentação por limiar divide os pixels segundo sua intensidade. O método de Otsu seleciona automaticamente o

limiar que maximiza a separação estatística entre classes do histograma (OTSU, 1979). Após a binarização, erosão e dilatação podem remover componentes pequenos, preencher falhas ou separar estruturas de acordo com o elemento estruturante utilizado.

Quando objetos próximos formam uma única região binária, a transformação *watershed* oferece uma alternativa para separá-los. A imagem é interpretada como uma superfície topográfica, e o processo de inundação estabelece linhas divisórias entre bacias associadas a diferentes marcadores (SZELISKI, 2022). Em uma sequência temporal, a subtração de fundo também pode destacar regiões cuja aparência se altera. Esses métodos clássicos são rápidos e interpretáveis, mas dependem de parâmetros sensíveis ao contraste, à iluminação, à deriva da câmera, à presença de detritos e à densidade celular. Nos vídeos de sêmen, uma região brilhante pode corresponder a uma cabeça, a um ruído ou a um aglomerado; portanto, uma segmentação visualmente plausível não é suficiente sem comparação com anotações de referência.

Na detecção de objetos, a saída deixa de ser apenas uma máscara binária e passa a conter, para cada instância, uma classe, uma caixa delimitadora e uma confiança. A família YOLO popularizou detectores de um estágio que formulam localização e classificação como uma predição conjunta feita por uma única rede neural, favorecendo aplicações em tempo real (REDMON et al., 2016). O VISEM-Tracking usa coordenadas normalizadas no formato YOLO e oferece três classes: espermatozoide normal, aglomerado e célula pequena ou *pinhead*. Seus autores treinaram variantes do YOLOv5 como validação técnica do conjunto de dados, demonstrando que as anotações podem sustentar modelos supervisionados (THAMBAWITA et al., 2023).

A detecção de espermatozoides é um caso de detecção de objetos pequenos. Poucos pixels descrevem cada cabeça, a textura individual é limitada, há borramento de movimento e oclusões ocorrem quando células se aproximam. Por isso, avanços recentes exploram resoluções maiores, camadas específicas para objetos pequenos, mecanismos de atenção e funções de custo mais adequadas à localização. Em um exemplo diretamente relacionado ao domínio, Zhang et al. (2024) adaptaram YOLOv8 e um rastreador baseado em aparência e movimento para o VISEM-Tracking. Esse tipo de resultado motiva a comparação entre um *baseline* clássico, como limiarização seguida de contornos, e um detector aprendido. A comparação deve considerar precisão, revocação, qualidade de localização e tempo de execução, pois melhorar somente um desses aspectos pode prejudicar as etapas temporais posteriores.

1.3 Rastreamento multiobjeto

Rastreamento multiobjeto, ou *Multi-Object Tracking* (MOT), é a tarefa de estimar simultaneamente o estado de vários objetos e manter um identificador consistente para cada

um ao longo de um vídeo. Na abordagem *tracking-by-detection*, cada quadro é processado por um detector e, em seguida, as novas observações são associadas às trajetórias existentes. O estado pode conter posição, tamanho da caixa e velocidade. Uma trajetória nasce quando uma detecção ainda não associada persiste, é atualizada enquanto recebe observações compatíveis e pode ser encerrada após permanecer ausente por certo número de quadros.

Dois fundamentos clássicos desse processo são estimação de estado e associação de dados. O filtro de Kalman representa a evolução do estado por um modelo linear com incertezas: primeiro prediz o estado no novo instante; depois corrige essa previsão com a medição observada, ponderando as covariâncias dos ruídos do processo e da medição (KALMAN, 1960). Para associar m trajetórias a n detecções, constrói-se uma matriz de custos com distâncias entre centroides, sobreposição entre caixas ou outra medida de similaridade. O algoritmo Húngaro resolve o problema de atribuição global de custo mínimo sob a restrição de correspondências um a um (BEWLEY et al., 2016). Uma regra de bloqueio, ou *gating*, impede associações fisicamente improváveis mesmo que elas minimizem o custo global.

O SORT reuniu filtro de Kalman, sobreposição entre caixas e associação Húngara em um rastreador simples e rápido, evidenciando também que a qualidade do detector limita o desempenho do rastreamento (BEWLEY et al., 2016). Posteriormente, o ByteTrack propôs duas etapas de associação: primeiro utiliza detecções de alta confiança e depois tenta recuperar objetos entre as detecções de baixa confiança, reduzindo o descarte prematuro de observações verdadeiras (ZHANG et al., 2022). Esses métodos ilustram a evolução de modelos baseados principalmente em movimento para combinações de movimento, localização, confiança e aparência.

No domínio espermático, a associação é dificultada pela alta densidade, pelas trajetórias rápidas e curvas e pela semelhança visual entre indivíduos. Descritores de reidentificação, eficazes quando pessoas apresentam roupas distintas, podem ser pouco discriminativos para cabeças com poucos pixels e aparência homogênea. Por outro lado, usar somente distância espacial falha em cruzamentos e movimentos bruscos. O VISEM-Tracking fornece identificadores manuais por célula e, portanto, permite medir trocas de identidade, fragmentações e recuperação após ausências (THAMBAWITA et al., 2023). Trabalhos recentes específicos do domínio combinam detectores adaptados a objetos pequenos com rastreadores que modelam melhor movimento e aparência, confirmando que detecção e associação precisam ser avaliadas conjuntamente (ZHANG et al., 2024).

1.4 Fluxo óptico e campo de movimento aparente

Fluxo óptico é um campo vetorial que descreve o deslocamento aparente de padrões de intensidade entre quadros. Para cada pixel (x, y) , procura-se um vetor de velocidade

aparente $\mathbf{v}(x, y) = (u, v)$, expresso em unidades de imagem por unidade de tempo, que o relacione à posição correspondente no instante seguinte. Partindo da hipótese de constância de brilho, $I(x, y, t) = I(x + u\Delta t, y + v\Delta t, t + \Delta t)$, uma aproximação de primeira ordem produz a equação de restrição

$$I_x u + I_y v + I_t = 0. \quad (1.3)$$

Como há uma equação para duas incógnitas, restrições adicionais são necessárias. Esse é um aspecto do problema de abertura: uma pequena vizinhança pode informar o movimento normal a uma borda, mas não determinar de modo único o deslocamento completo (SZELISKI, 2022).

Os métodos clássicos diferem na regularização adotada. Lucas e Kanade supõem movimento aproximadamente constante em uma vizinhança e resolvem localmente um sistema de mínimos quadrados, sendo frequentemente usados para rastrear pontos característicos. Horn e Schunck formulam uma otimização global que combina constância de brilho e suavidade do campo. Farnebäck aproxima vizinhanças por polinômios e estima um campo denso em múltiplas escalas, constituindo uma alternativa prática para vídeos quando se deseja um vetor em cada região da imagem (SZELISKI, 2022). Pirâmides de resolução ajudam esses métodos a lidar com deslocamentos maiores entre quadros, mas borramento, regiões sem textura, oclusões e alterações de iluminação continuam produzindo ambiguidades.

O aprendizado profundo alterou a estimação de fluxo ao aprender correspondências a partir de bases com deslocamento conhecido. O RAFT constrói volumes de correlação para todos os pares de características e atualiza iterativamente um campo de fluxo por uma unidade recorrente (TEED; DENG, 2020). A arquitetura obteve ganhos importantes em conjuntos como Sintel e KITTI, mas sua transferência para microscopia deve ser verificada experimentalmente, pois escala, textura e formação da imagem diferem das cenas usadas no treinamento. Assim, Farnebäck funciona como referência clássica de baixo custo, enquanto RAFT representa uma alternativa moderna cuja maior complexidade só se justifica se houver ganho mensurável no domínio estudado.

Neste trabalho, o fluxo óptico possui dois usos potenciais. O primeiro é estimar movimento global do fundo, inclusive deriva da câmera, para evitar atribuí-lo ao deslocamento individual. O segundo é extrair, na vizinhança de cada célula, componentes de movimento que possam ser adicionadas às características da trajetória. É essencial, porém, distinguir fluxo óptico de velocidade física do fluido. O fluxo é uma medida em coordenadas de imagem e mistura o movimento das células, do meio visível, de artefatos e da câmera. Como VISEM e VISEM-Tracking não fornecem um campo físico de velocidade como verdade de referência, qualquer interpretação como “corrente do fluido” deve ser apresentada como estimativa visual indireta e validada por critérios compatíveis com essa limitação (HAUGEN et al., 2019; THAMBAWITA et al., 2023).

1.5 Predição de trajetórias

Predição de trajetória estima posições futuras a partir de uma sequência observada. Se $\mathbf{p}_{t-h+1:t}$ representa um histórico de h posições, o objetivo é aprender ou definir uma função que produza $\hat{\mathbf{p}}_{t+1:t+q}$ para um horizonte de q instantes. A tarefa difere do rastreamento: o rastreador estima o estado atual e resolve identidades com medições já disponíveis, enquanto o preditor é avaliado em instantes cujas posições reais são ocultadas durante a inferência. Essa separação evita que erros de detecção e associação sejam confundidos com a capacidade preditiva do modelo.

Modelos cinemáticos simples constituem referências importantes. Uma extrapolação de velocidade constante usa o deslocamento recente para projetar a posição. O filtro de Kalman estende essa ideia ao incorporar ruídos de processo e medição e pode ser configurado com estado de posição e velocidade (KALMAN, 1960). Esses modelos são interpretáveis e exigem poucos dados, mas tendem a degradar quando a célula muda rapidamente de direção ou velocidade. Um filtro mais complexo não deve ser escolhido apenas por produzir curvas visualmente suaves; ele precisa reduzir o erro em horizontes definidos e sob a mesma partição de dados.

Redes recorrentes foram desenvolvidas para representar dependências em sequências. A LSTM introduz células de memória e portas de controle que atenuam o problema de gradientes que desaparecem em redes recorrentes convencionais (HOCHREITER; SCHMIDHUBER, 1997). Em predição de trajetórias, posições ou deslocamentos sucessivos são codificados em um estado oculto, do qual o decodificador gera coordenadas futuras. O Social LSTM mostrou, em trajetórias de pedestres, como estados recorrentes podem ser combinados para considerar interações entre agentes (ALAHY et al., 2016). Embora a dinâmica humana não seja transferível diretamente para espermatozoides, a formulação sequência-para-sequência e as métricas de deslocamento são referências úteis. Avanços posteriores incorporaram grafos, distribuições multimodais e mecanismos de atenção; modelos baseados em Transformer, por exemplo, representam dependências temporais com atenção em vez de depender exclusivamente de recorrência (SHI et al., 2023).

A hipótese computacional central deste TCC é que informação de movimento aparente pode complementar o histórico geométrico. Um modelo sem fluxo pode receber $(x, y, \Delta x, \Delta y)$, enquanto outro inclui $(u, v, \|\mathbf{v}\|, \theta)$ amostrados do campo óptico. A comparação deve manter arquitetura, histórico, horizonte e divisão dos dados controlados, alterando somente as características de fluxo. Dessa forma, será possível verificar se elas reduzem o erro, produzem resultado equivalente ou introduzem ruído. O filtro de Kalman fornece o *baseline* clássico; uma LSTM ou GRU oferece um modelo neural de complexidade moderada; e arquiteturas mais pesadas devem ser consideradas apenas se a quantidade de trajetórias e os recursos computacionais sustentarem uma avaliação reproduzível.

1.6 Conjuntos de dados e métricas de avaliação

Uma fundamentação experimental precisa especificar o que é observado e o que serve como verdade de referência. O VISEM original contém 85 vídeos microscópicos associados a resultados de análise seminal e outros dados dos participantes, mas não fornece identificadores de rastreamento quadro a quadro (HAUGEN et al., 2019). O VISEM-Tracking seleciona 20 vídeos de 30 segundos, totalizando 29.196 quadros, e acrescenta caixas delimitadoras, classes e identificadores persistentes verificados por especialistas (THAMBAWITA et al., 2023). Por isso, o segundo conjunto é adequado para treinar e avaliar detecção e rastreamento, enquanto o primeiro amplia o contexto multimodal. As partições de treinamento, validação e teste devem ser feitas por vídeo ou participante, e não por quadros aleatórios, para impedir que imagens quase idênticas da mesma sequência apareçam nos dois lados da avaliação.

Na detecção, precisão e revocação se baseiam em verdadeiros positivos (VP), falsos positivos (FP) e falsos negativos (FN):

$$\text{Precisão} = \frac{\text{VP}}{\text{VP} + \text{FP}}, \quad \text{Revocação} = \frac{\text{VP}}{\text{VP} + \text{FN}}. \quad (1.4)$$

Uma detecção é considerada correspondente ao gabarito quando a interseção sobre união (*Intersection over Union*, IoU) ultrapassa um limiar. A área sob a curva de precisão-revocação gera a precisão média (AP), e a média entre classes ou limiares gera a mAP. Como células pequenas tornam a IoU sensível a poucos pixels de deslocamento, também é pertinente analisar erros de centroide e resultados por classe, além da métrica agregada.

No rastreamento, MOTA combina falsos positivos, falsos negativos e trocas de identidade, normalizados pela quantidade de objetos do gabarito. IDF1 mede a preservação de identidade por meio da média harmônica entre precisão e revocação calculadas no espaço de associações. HOTA foi proposta para equilibrar, em uma única família de medidas, qualidade de detecção, associação e localização, evitando que um único tipo de erro domine toda a interpretação (LUITEN et al., 2021). Neste projeto, HOTA deve ser a métrica principal de rastreamento, acompanhada por MOTA, IDF1, número de trocas de identidade, fragmentações e tempo por quadro. A inspeção de vídeos anotados continua necessária para explicar em quais situações os erros ocorrem.

Para um conjunto de N trajetórias e horizonte de q passos, o erro médio de deslocamento (ADE) e o erro de deslocamento final (FDE) podem ser escritos como

$$\text{ADE} = \frac{1}{Nq} \sum_{i=1}^N \sum_{k=1}^q \|\hat{\mathbf{p}}_{i,t+k} - \mathbf{p}_{i,t+k}\|_2, \quad (1.5)$$

$$\text{FDE} = \frac{1}{N} \sum_{i=1}^N \|\hat{\mathbf{p}}_{i,t+q} - \mathbf{p}_{i,t+q}\|_2. \quad (1.6)$$

O ADE resume o erro ao longo de todo o horizonte, enquanto o FDE enfatiza a posição mais distante no tempo (ALAHY et al., 2016). Ambos devem ser reportados no mesmo sistema de

coordenadas e, quando possível, também convertidos para unidade física. Resultados médios precisam ser acompanhados por dispersão e por análise segundo duração de trajetória, densidade de células e horizonte, pois uma média única pode esconder falhas em sequências difíceis.

1.7 Articulação dos conceitos no trabalho

Os conceitos discutidos formam uma cadeia experimental, mas devem permanecer modularizados. O vídeo é convertido em quadros; o detector produz caixas e centroides; o rastreador associa essas observações e forma trajetórias; o módulo de fluxo estima movimento aparente entre quadros; e o preditor utiliza o histórico, com ou sem características de fluxo, para gerar posições futuras. Essa separação permite substituir uma técnica sem redefinir as demais e permite medir a origem dos erros. Por exemplo, a predição pode ser inicialmente avaliada sobre trajetórias manuais do VISEM-Tracking, isolando o modelo preditivo, e depois sobre trajetórias produzidas pelo rastreador, medindo a degradação da pipeline completa.

A progressão experimental parte de métodos clássicos, interpretáveis e computacionalmente acessíveis, para abordagens aprendidas. Limiarização e morfologia estabelecem a referência de detecção; filtro de Kalman e associação Húngara estabelecem a referência temporal; Farnebäck estabelece a referência de fluxo denso; e extrapolação ou Kalman estabelecem a referência de predição. YOLO, ByteTrack, RAFT e modelos recorrentes representam evoluções modernas a serem incorporadas sob os mesmos dados e critérios. A contribuição científica não está em simplesmente reunir essas ferramentas, mas em avaliar, com controles e métricas adequados, se a informação de fluxo melhora a análise e a predição de trajetórias de espermatozoides e sob quais condições isso ocorre.

1.8 Declaração sobre o uso de Inteligência Artificial

Ferramentas de Inteligência Artificial generativa foram utilizadas como apoio à pesquisa bibliográfica e à revisão linguística e de formatação. O tema, o recorte do problema, a argumentação e as decisões metodológicas são de responsabilidade do autor, que realizou a seleção das fontes e a revisão final do conteúdo.

REFERÊNCIAS

- ALAHÍ, A. et al. Social lstm: Human trajectory prediction in crowded spaces. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. [s.n.], 2016. p. 961–971. Disponível em: <<https://doi.org/10.1109/CVPR.2016.110>>. Citado 2 vezes nas páginas 7 e 8.
- BEWLEY, A. et al. Simple online and realtime tracking. In: *2016 IEEE International Conference on Image Processing*. [s.n.], 2016. p. 3464–3468. Disponível em: <<https://doi.org/10.1109/ICIP.2016.7533003>>. Citado na página 5.
- HAUGEN, T. B. et al. Visem: A multimodal video dataset of human spermatozoa. In: *Proceedings of the 10th ACM Multimedia Systems Conference*. New York: Association for Computing Machinery, 2019. p. 261–266. Disponível em: <<https://doi.org/10.1145/3304109.3325814>>. Citado 4 vezes nas páginas 2, 3, 6 e 8.
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, v. 9, n. 8, p. 1735–1780, 1997. Disponível em: <<https://doi.org/10.1162/neco.1997.9.8.1735>>. Citado na página 7.
- KALMAN, R. E. A new approach to linear filtering and prediction problems. *Journal of Basic Engineering*, v. 82, n. 1, p. 35–45, 1960. Disponível em: <<https://doi.org/10.1115/1.3662552>>. Citado 2 vezes nas páginas 5 e 7.
- LUITEN, J. et al. Hota: A higher order metric for evaluating multi-object tracking. *International Journal of Computer Vision*, v. 129, n. 2, p. 548–578, 2021. Disponível em: <<https://doi.org/10.1007/s11263-020-01375-2>>. Citado na página 8.
- OTSU, N. A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, v. 9, n. 1, p. 62–66, 1979. Disponível em: <<https://doi.org/10.1109/TSMC.1979.4310076>>. Citado na página 4.
- REDMON, J. et al. You only look once: Unified, real-time object detection. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. [s.n.], 2016. p. 779–788. Disponível em: <<https://doi.org/10.1109/CVPR.2016.91>>. Citado na página 4.
- SHI, L. et al. Trajectory unified transformer for pedestrian trajectory prediction. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. [s.n.], 2023. p. 9675–9684. Disponível em: <https://openaccess.thecvf.com/content/ICCV2023/html/Shi_Trajectory_Unified_Transformer_for_Pedestrian_Trajectory_Prediction_ICCV_2023_paper.html>. Citado na página 7.
- SZELISKI, R. *Computer Vision: Algorithms and Applications*. 2. ed. Cham: Springer, 2022. Disponível em: <<https://doi.org/10.1007/978-3-030-34372-9>>. Citado 2 vezes nas páginas 4 e 6.
- TEED, Z.; DENG, J. Raft: Recurrent all-pairs field transforms for optical flow. In: *Computer Vision – ECCV 2020*. Cham: Springer, 2020. (Lecture Notes in Computer Science, v. 12347), p. 402–419. Disponível em: <https://doi.org/10.1007/978-3-030-58536-5_24>. Citado na página 6.

THAMBAWITA, V. et al. Visem-tracking, a human spermatozoa tracking dataset. *Scientific Data*, v. 10, n. 1, p. 260, 2023. Disponível em: <<https://doi.org/10.1038/s41597-023-02173-4>>. Citado 5 vezes nas páginas 3, 4, 5, 6 e 8.

World Health Organization. *WHO Laboratory Manual for the Examination and Processing of Human Semen*. 6. ed. Geneva: World Health Organization, 2021. ISBN 978-92-4-003078-7. Disponível em: <<https://www.who.int/publications/i/item/9789240030787>>. Acesso em: 27 jul. 2026. Citado 2 vezes nas páginas 2 e 3.

ZHANG, C. et al. Sperm yolov8e-trackevd: A novel approach for sperm detection and tracking. *Sensors*, v. 24, n. 11, p. 3493, 2024. Disponível em: <<https://doi.org/10.3390/s24113493>>. Citado 2 vezes nas páginas 4 e 5.

ZHANG, Y. et al. Bytetrack: Multi-object tracking by associating every detection box. In: *Computer Vision – ECCV 2022*. Cham: Springer, 2022. (Lecture Notes in Computer Science, v. 13682), p. 1–21. Disponível em: <https://doi.org/10.1007/978-3-031-20047-2_1>. Citado na página 5.