

Disciplina: FACOM31704 – Metodologia Científica em Computação e Informática

Professor: Prof. Dr. Rafael Dias Araújo

Estudante: Leandro Marques Gontijo Jersé

Orientador(a): Prof. Dr. Bruno Augusto Nassif Travencolo

Tipo de trabalho: Projeto de Pesquisa Tradicional

Entrega 4 (E4) – Método

1 MÉTODO PROPOSTO

O trabalho será conduzido como uma pesquisa aplicada, quantitativa e experimental em Visão Computacional. O método consistirá na implementação e na avaliação controlada de uma pipeline para detecção, rastreamento multiobjeto, estimação de movimento aparente e predição de trajetórias de espermatozoides em vídeos microscópicos. A hipótese computacional a ser examinada é que a inclusão de informações locais de fluxo óptico, associadas ao histórico de posições de cada célula, pode reduzir o erro de predição de posições futuras em comparação com modelos equivalentes que utilizem somente posição e velocidade. Essa formulação permite verificar o objetivo por meio de experimentos reproduzíveis, em consonância com a definição de método como a sequência de procedimentos necessária para demonstrar se o objetivo foi atingido ([WAZLAWICK, 2020](#)).

1.1 Produtos e dados da pesquisa

Os produtos derivados serão: uma coleção de dados organizada com divisões experimentais documentadas; uma pipeline modular em Python; modelos treinados de detecção, rastreamento, fluxo óptico e predição; arquivos contendo caixas delimitadoras, identificadores, trajetórias e campos vetoriais estimados; e uma análise comparativa apresentada por métricas, tabelas e visualizações. O código e os modelos serão artefatos necessários à realização dos experimentos, enquanto o produto científico principal será a evidência sobre o efeito do fluxo óptico na qualidade do rastreamento e, sobretudo, da predição de trajetórias.

O VISEM-Tracking será empregado como base pública para o treinamento e a avaliação inicial dos módulos supervisionados. Ele contém 20 vídeos de 30 segundos, totalizando 29.196 quadros, com caixas delimitadoras, classes e identificadores persistentes de rastreamento ([THAMBAWITA et al., 2023](#)). Os vídeos microscópicos do cenário-alvo, nos quais existe contracorrente gerada por um tubo, serão utilizados para avaliar a pipeline no domínio específico do TCC. Quando esses vídeos não apresentarem anotações completas, será selecionado um subconjunto representativo de trechos para anotação de caixas e identidades, com verificação de consistência temporal. As divisões de treinamento, validação e teste serão feitas por vídeo, e nunca por quadros isolados, para impedir que imagens consecutivas de uma mesma sequência apareçam simultaneamente no treinamento e no teste.

1.2 Levantamento, geração e organização dos dados

Inicialmente, serão registrados para cada vídeo a resolução, a taxa de quadros, a duração, a escala espacial quando disponível e as condições de aquisição. Os quadros serão extraídos preservando a ordem temporal e vinculados a um identificador único de vídeo. O pré-processamento será limitado a operações cuja influência possa ser controlada, como conversão de cor, normalização de intensidade, correção moderada de contraste e redução de ruído. As caixas e identidades existentes serão convertidas para uma representação comum, e as coordenadas das trajetórias serão obtidas a partir do centro das caixas. Também serão mantidos os valores originais para que qualquer transformação possa ser revertida e auditada.

Para reduzir vazamento de informação, será adotada uma separação fixa de vídeos em conjuntos de treinamento, validação e teste. O treinamento será usado para estimar os parâmetros dos modelos, a validação para escolher hiperparâmetros e critérios de parada, e o teste permanecerá isolado até a configuração final. Nos vídeos do cenário-alvo, a divisão respeitará a unidade de aquisição disponível, como amostra, paciente ou sessão, evitando que trechos derivados da mesma origem sejam distribuídos entre conjuntos distintos. Os arquivos de configuração registrarão divisões, sementes aleatórias, versões das bibliotecas e parâmetros experimentais.

1.3 Detecção e rastreamento multiobjeto

A detecção será iniciada com uma linha de base clássica baseada em limiarização, operações morfológicas e componentes conexos. Em seguida, será treinado um detector da família YOLO com as anotações do VISEM-Tracking. A comparação entre a abordagem clássica e a aprendida permitirá medir quanto o aprendizado supervisionado contribui em cenas com baixo contraste, alta densidade e objetos pequenos. Para cada configuração serão registradas precisão, revocação, mAP@0,5 e mAP@0,5:0,95, além do tempo médio de processamento por quadro. O detector especializado proposto por Zhang et al. (ZHANG et al., 2024) será usado como referência de desempenho no domínio espermático, respeitadas as diferenças de divisão dos dados e de ambiente computacional.

As detecções serão associadas temporalmente por métodos de complexidade crescente. O primeiro será um rastreador por proximidade entre centroides; o segundo será o SORT, que combina Filtro de Kalman e associação pelo algoritmo Húngaro (BEWLEY et al., 2016); e o terceiro será o ByteTrack, que aproveita detecções de diferentes níveis de confiança para reduzir interrupções das trajetórias (ZHANG et al., 2022). Os limiares de associação e o número de quadros tolerados sem detecção serão escolhidos no conjunto de validação. As saídas terão a forma (v, t, i, x, y) , em que v identifica o vídeo, t o quadro, i o espermatozoide e (x, y) a posição do centro da célula.

1.4 Estimação do movimento aparente

O fluxo óptico denso será estimado inicialmente pelo método de Farnebäck, escolhido como linha de base por seu custo moderado e disponibilidade no OpenCV ([FARNEBÄCK, 2003](#)). Se os recursos computacionais permitirem, o RAFT será incluído como alternativa baseada em aprendizado profundo ([TEED; DENG, 2020](#)). Antes do cálculo do fluxo, movimentos globais da câmera serão estimados e compensados quando detectados. As regiões ocupadas pelas células e por artefatos evidentes serão mascaradas para reduzir sua influência na estimativa do movimento do meio; em seguida, os vetores restantes serão agregados de forma robusta e suavizados espacial e temporalmente.

Como os conjuntos considerados não fornecem uma medição física do campo de velocidade do fluido, o resultado será denominado campo de movimento aparente. Sua validação será feita por erro fotométrico após a deformação de um quadro em direção ao seguinte, consistência entre os fluxos direto e reverso, regularidade temporal e estabilidade dos vetores nas regiões de fundo. Sequências sintéticas com deslocamentos conhecidos poderão complementar essa análise. Assim, o método evitará interpretar automaticamente deslocamentos em pixels como velocidade física; a conversão para unidades físicas somente será realizada quando houver calibração espacial e temporal confiável.

1.5 Predição das trajetórias

Cada trajetória válida será dividida em uma janela observada de p quadros e um horizonte futuro de q quadros. As entradas básicas serão posição, deslocamento e velocidade estimada; as configurações com fluxo acrescentarão o vetor aparente amostrado na posição da célula e estatísticas de uma vizinhança local. Serão comparados um modelo de velocidade constante baseado no Filtro de Kalman, uma rede LSTM e, se houver ganho justificável, uma GRU. A LSTM foi escolhida por modelar dependências temporais e já ter sido aplicada à previsão da localização de espermatozoides ([NOY et al., 2023](#)).

O experimento principal será uma ablação pareada: o mesmo preditor, com os mesmos dados, janelas, hiperparâmetros e sementes, será treinado primeiro sem fluxo e depois com as características de fluxo. Desse modo, a alteração controlada será a presença do movimento aparente, e não uma mudança simultânea de arquitetura. A avaliação será realizada em dois cenários. No primeiro, serão usadas trajetórias anotadas, isolando o desempenho do preditor; no segundo, serão usadas trajetórias produzidas pelo rastreador, medindo a degradação da pipeline completa. Os resultados serão separados por horizonte de previsão, densidade de células e comprimento da trajetória.

1.6 Critérios de validação e comparação

Na detecção serão utilizadas precisão, revocação e mAP. No rastreamento, a métrica principal será HOTA, que equilibra a qualidade da detecção e da associação de identidades, acompanhada de MOTA, IDF1, número de trocas de identidade e fragmentações (LUITEN et al., 2021). Na predição serão calculados o erro médio de deslocamento (ADE) ao longo do horizonte e o erro de deslocamento final (FDE), métricas utilizadas em trabalhos de previsão de trajetórias (ALAHY et al., 2016). Os erros serão expressos em pixels normalizados e, quando houver calibração, também em micrômetros.

As comparações serão feitas entre linhas de base clássicas e métodos modernos, entre o preditor sem fluxo e com fluxo e entre trajetórias anotadas e trajetórias estimadas. Para evitar que vídeos longos dominem a média, os resultados serão agregados primeiro por trajetória e depois por vídeo. Serão informados média, mediana, desvio-padrão e intervalo de confiança de 95% obtido por reamostragem dos vídeos. Quando forem executados treinamentos estocásticos, cada configuração será repetida com sementes diferentes. Uma melhoria somente será considerada consistente quando aparecer nas métricas principais, nos intervalos de confiança e na inspeção qualitativa de casos de sucesso e falha.

Em relação aos trabalhos relacionados, os resultados de detecção e rastreamento no VISEM-Tracking serão confrontados com os protocolos e métricas publicados por Thambawita et al. (THAMBAWITA et al., 2023) e Zhang et al. (ZHANG et al., 2024). A predição será comparada à linha de base de velocidade constante e ao uso de LSTM descrito por Noy et al. (NOY et al., 2023). Diferenças de divisão dos dados, resolução, horizonte, hardware e implementação serão explicitadas, evitando tratar números obtidos em condições distintas como uma comparação direta.

1.7 Etapas de desenvolvimento

1. **Auditoria e padronização dos dados.** Os vídeos, metadados e anotações serão inventariados, convertidos para formatos comuns e verificados visualmente. Essa etapa é necessária para evitar que erros de sincronização ou coordenadas contaminem todos os módulos seguintes.
2. **Definição das divisões e linhas de base.** Serão fixados os conjuntos de treinamento, validação e teste, as sementes e as linhas de base clássicas. A definição antecipada reduz escolhas orientadas pelos resultados do teste e estabelece referências mínimas para as abordagens mais complexas.
3. **Treinamento e avaliação da detecção.** A abordagem clássica e o detector aprendido serão ajustados e comparados. O marco dessa etapa será a escolha de uma configuração capaz de fornecer detecções suficientemente estáveis para o rastreamento.

4. **Implementação do rastreamento.** Os métodos por centroide, SORT e ByteTrack serão aplicados às mesmas detecções. Essa ordem permite separar falhas causadas pelo detector das falhas de associação e selecionar o rastreador usado na pipeline.
5. **Estimação e análise do fluxo.** Farnebäck e, se viável, RAFT serão executados com compensação de movimento global e máscaras de primeiro plano. As verificações de consistência determinarão se os vetores são estáveis o bastante para serem usados como atributos de predição.
6. **Construção dos conjuntos de predição.** As trajetórias serão filtradas, normalizadas e convertidas em pares de janelas observadas e futuras. As características com e sem fluxo serão geradas a partir das mesmas amostras para garantir comparabilidade.
7. **Treinamento e ablação dos preditores.** O modelo de velocidade constante e os modelos recorrentes serão avaliados nos cenários controlados. O marco será quantificar se a inclusão do fluxo reduz ADE e FDE e em quais condições esse efeito ocorre.
8. **Análise final e documentação.** Os resultados serão agregados, acompanhados de intervalos de confiança, gráficos e exemplos de falha. Por fim, serão registrados parâmetros, limitações e condições de reprodução, permitindo relacionar as evidências obtidas à hipótese e aos trabalhos relacionados.

1.8 Resumo sobre os Capítulos 8 e 9

No Capítulo 8, Wazlawick ([WAZLAWICK, 2020](#)) discute a escrita da monografia como a comunicação ordenada de uma contribuição, e não como um diário das atividades realizadas. O texto deve ser estruturado para conduzir o leitor do problema e da fundamentação até o desenvolvimento, os resultados e as conclusões. O autor também considera a forma como a banca costuma ler o trabalho e recomenda que título, resumo e introdução apresentem com clareza o objetivo e a contribuição, mantendo coerência com o restante do documento.

O capítulo detalha as funções das partes principais. A revisão bibliográfica deve fornecer os conceitos indispensáveis e posicionar os trabalhos relacionados; o desenvolvimento deve explicar o método, os experimentos e as evidências produzidas, sem transformar a monografia em um manual do software implementado; e a conclusão deve retomar o objetivo, sintetizar os resultados, indicar limitações e separar contribuições científicas dos artefatos técnicos. Os trabalhos futuros devem apontar questões de pesquisa que permaneceram abertas, enquanto as referências devem conter somente as obras efetivamente citadas. A escrita científica, por fim, deve privilegiar precisão, encadeamento lógico e ausência de ambiguidades.

No Capítulo 9, o autor trata da escrita de artigos científicos. A autoria deve corresponder a uma contribuição intelectual efetiva, e a motivação para publicar deve estar ligada à comunicação de conhecimento relevante à comunidade. Um artigo precisa deixar evidente o problema, a relação com estudos anteriores e a contribuição produzida. Como o espaço costuma ser menor que o de uma monografia, a seleção do conteúdo deve ser rigorosa: detalhes secundários são reduzidos, mas as informações necessárias para compreender o método e avaliar os resultados devem permanecer.

Wazlawick ([WAZLAWICK, 2020](#)) distingue artigos teóricos, relatos de experiência e artigos sobre métodos, cada qual com formas de evidência adequadas. O capítulo também aborda a escolha do veículo de publicação, considerando escopo, público, revisão por pares e relevância na área. Por fim, enfatiza princípios éticos, como evitar submissão simultânea do mesmo manuscrito, reconhecer corretamente as contribuições dos autores e respeitar as regras editoriais. Indicadores de impacto e classificações podem auxiliar na escolha do veículo, mas não substituem a compatibilidade entre o trabalho e a comunidade à qual ele se destina.

1.9 Declaração sobre o uso de Inteligência Artificial

Para esta entrega, utilizei as ferramentas ChatGPT e Codex, da OpenAI, como apoio à pesquisa bibliográfica, à organização inicial da descrição metodológica, à conferência dos metadados das referências, à revisão linguística e à formatação do documento em LaTeX. Eu conferi a coerência do método com os objetivos e com as entregas anteriores, e o texto será submetido somente após a revisão e a concordância do orientador.

REFERÊNCIAS

- ALAHÍ, A. et al. Social LSTM: Human trajectory prediction in crowded spaces. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. [s.n.], 2016. p. 961–971. Disponível em: <<https://doi.org/10.1109/CVPR.2016.110>>. Citado na página 5.
- BEWLEY, A. et al. Simple online and realtime tracking. In: *2016 IEEE International Conference on Image Processing*. [s.n.], 2016. p. 3464–3468. Disponível em: <<https://doi.org/10.1109/ICIP.2016.7533003>>. Citado na página 3.
- FARNEBÄCK, G. Two-frame motion estimation based on polynomial expansion. In: *Scandinavian Conference on Image Analysis*. Berlin: Springer, 2003. (Lecture Notes in Computer Science, v. 2749), p. 363–370. Disponível em: <https://doi.org/10.1007/3-540-45103-X_50>. Citado na página 4.
- LUITEN, J. et al. HOTA: A higher order metric for evaluating multi-object tracking. *International Journal of Computer Vision*, v. 129, n. 2, p. 548–578, 2021. Disponível em: <<https://doi.org/10.1007/s11263-020-01375-2>>. Citado na página 5.
- NOY, L. et al. Location prediction of sperm cells using long short-term memory networks. *Advanced Intelligent Systems*, Wiley, v. 5, n. 9, p. 2300161, 2023. Disponível em: <<https://doi.org/10.1002/aisy.202300161>>. Citado 2 vezes nas páginas 4 e 5.
- TEED, Z.; DENG, J. RAFT: Recurrent all-pairs field transforms for optical flow. In: *Computer Vision – ECCV 2020*. Cham: Springer, 2020. (Lecture Notes in Computer Science, v. 12347), p. 402–419. Disponível em: <https://doi.org/10.1007/978-3-030-58536-5_24>. Citado na página 4.
- THAMBAWITA, V. et al. VISEM-Tracking, a human spermatozoa tracking dataset. *Scientific Data*, Springer Nature, v. 10, n. 1, p. 260, 2023. Disponível em: <<https://doi.org/10.1038/s41597-023-02173-4>>. Citado 2 vezes nas páginas 2 e 5.
- WAZLAWICK, R. S. *Metodologia de Pesquisa para Ciência da Computação*. 3. ed. Rio de Janeiro: GEN LTC, 2020. Citado 3 vezes nas páginas 2, 6 e 7.
- ZHANG, C. et al. Sperm YOLOv8E-TrackEVD: A novel approach for sperm detection and tracking. *Sensors*, MDPI, v. 24, n. 11, p. 3493, 2024. Disponível em: <<https://doi.org/10.3390/s24113493>>. Citado 2 vezes nas páginas 3 e 5.
- ZHANG, Y. et al. ByteTrack: Multi-object tracking by associating every detection box. In: *Computer Vision – ECCV 2022*. Cham: Springer, 2022. (Lecture Notes in Computer Science, v. 13682), p. 1–21. Disponível em: <https://doi.org/10.1007/978-3-031-20047-2_1>. Citado na página 3.