
Análise e Predição de Trajetórias de Espermatozoides em Vídeos Microscópicos

Leandro Marques Gontijo Jersé



UNIVERSIDADE FEDERAL DE UBERLÂNDIA
FACULDADE DE COMPUTAÇÃO
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

Leandro Marques Gontijo Jersé

**Análise e Predição de Trajetórias de
Espermatozoides em Vídeos Microscópicos**

Trabalho de Conclusão de Curso apresentado à Faculdade de Computação da Universidade Federal de Uberlândia, Minas Gerais, como requisito parcial para a obtenção do Título de Bacharel em Ciência da Computação

Área de concentração: Ciência da Computação

Orientador: Prof. Dr. Bruno Augusto Nassif Travencolo

Uberlândia - MG

2026

Resumo

Este trabalho investiga a análise e a predição de trajetórias de espermatozoides em vídeos microscópicos por meio de técnicas de Visão Computacional. O problema envolve objetos pequenos, visualmente semelhantes e de baixo contraste, cujos movimentos rápidos, irregulares e sujeitos a sobreposições dificultam a detecção e a preservação de identidades ao longo do tempo. O objetivo é implementar e avaliar uma pipeline composta por detecção, rastreamento multiobjeto, estimação de movimento aparente por fluxo óptico e predição de posições futuras. A pesquisa será aplicada, quantitativa e experimental. Serão utilizados o conjunto público VISEM-Tracking e vídeos do cenário-alvo com contracorrente gerada por um tubo, organizados em divisões independentes por vídeo ou unidade de aquisição. Métodos clássicos, como limiarização, Filtro de Kalman, SORT e Farnebäck, serão comparados a abordagens aprendidas, como YOLO, ByteTrack, RAFT e redes recorrentes. A hipótese principal é que características locais de fluxo óptico, combinadas ao histórico de posições, podem reduzir os erros ADE e FDE em relação a preditores equivalentes que utilizem somente posição e velocidade. A avaliação também utilizará métricas de detecção e rastreamento, com atenção à reprodutibilidade e à distinção entre movimento aparente na imagem e velocidade física do fluido.

Palavras-chave: Visão computacional, espermatozoides, rastreamento multiobjeto, fluxo óptico, predição de trajetórias.

Abstract

This work investigates the analysis and prediction of spermatozoa trajectories in microscopy videos using Computer Vision techniques. The problem involves small, visually similar, low-contrast objects whose fast and irregular motion, overlaps, and temporary occlusions make detection and identity preservation difficult. The objective is to implement and evaluate a pipeline composed of detection, multi-object tracking, apparent-motion estimation through optical flow, and future-position prediction. The study will follow an applied, quantitative, and experimental design. The public VISEM-Tracking dataset and target-domain videos containing a tube-generated counter-current will be organized into independent splits by video or acquisition unit. Classical methods, including thresholding, Kalman filtering, SORT, and Farnebäck optical flow, will be compared with learned approaches such as YOLO, ByteTrack, RAFT, and recurrent neural networks. The main hypothesis is that local optical-flow features combined with position histories can reduce ADE and FDE relative to equivalent predictors that use only position and velocity. Detection and tracking metrics will also be reported, with emphasis on reproducibility and on the distinction between image-based apparent motion and the physical velocity of the fluid.

Keywords: Computer vision. Spermatozoa. Multi-object tracking. Optical flow. Trajectory prediction.

Lista de tabelas

Tabela 1 – Comparação dos trabalhos relacionados	21
--	----

Lista de siglas

ADE	Erro Médio de Deslocamento – <i>Average Displacement Error</i>
CASA	Análise Seminal Assistida por Computador – <i>Computer-Aided Sperm Analysis</i>
FDE	Erro de Deslocamento Final – <i>Final Displacement Error</i>
GRU	Unidade Recorrente Fechada – <i>Gated Recurrent Unit</i>
HOTA	Acurácia de Rastreamento de Ordem Superior – <i>Higher Order Tracking Accuracy</i>
IDF1	medida F1 de identificação
IoU	Interseção sobre União – <i>Intersection over Union</i>
LIN	linearidade
LSTM	Memória de Longo e Curto Prazo – <i>Long Short-Term Memory</i>
mAP	precisão média – <i>mean Average Precision</i>
MOT	Rastreamento Multiobjeto – <i>Multi-Object Tracking</i>
MOTA	Acurácia de Rastreamento Multiobjeto – <i>Multi-Object Tracking Accuracy</i>
VAP	velocidade do percurso médio
VCL	velocidade curvilínea
VSL	velocidade em linha reta

Lista de símbolos

Δt	intervalo de tempo entre dois quadros consecutivos
$\mathbf{p}_t$	posição bidimensional de uma célula no quadro t
p	quantidade de quadros da janela observada
q	quantidade de quadros do horizonte de predição
T	quantidade de posições de uma trajetória
u, v	componentes horizontal e vertical do fluxo óptico

Sumário

1	INTRODUÇÃO	9
1.1	Motivação	9
1.2	Problema	10
1.3	Hipótese	11
1.4	Objetivos	11
1.4.1	Objetivo geral	11
1.4.2	Objetivos específicos	11
1.5	Contribuições esperadas	12
1.6	Organização da Monografia	12
2	FUNDAMENTAÇÃO TEÓRICA	13
2.1	Análise seminal assistida por computador	13
2.2	Processamento de imagens e detecção	14
2.3	Rastreamento multiobjeto	15
2.4	Fluxo óptico e movimento aparente	15
2.5	Predição de trajetórias	16
2.6	Conjuntos de dados	17
2.7	Métricas de avaliação	17
3	TRABALHOS RELACIONADOS	19
3.1	Comparação entre os trabalhos	20
3.2	Lacuna investigada	21
4	MÉTODO	22
4.1	Produtos e dados da pesquisa	22
4.2	Levantamento, geração e organização dos dados	22
4.3	Detecção e rastreamento multiobjeto	23
4.4	Estimação do movimento aparente	23

4.5	Predição das trajetórias	24
4.6	Critérios de validação e comparação	24
4.7	Etapas de desenvolvimento	25
4.8	Declaração sobre o uso de Inteligência Artificial	25
5	CONCLUSÃO	26
5.1	Expectativas para a continuidade	26
REFERÊNCIAS		28

Introdução

Este Trabalho de Conclusão de Curso investiga a análise e a predição de trajetórias de espermatozoides em vídeos microscópicos por meio de técnicas de Visão Computacional. O estudo está inserido no contexto dos sistemas de análise seminal assistida por computador, conhecidos como Análise Seminal Assistida por Computador (CASA), nos quais vídeos de amostras seminais são utilizados para observar o deslocamento celular e extrair informações relacionadas à motilidade. A automatização dessa análise exige transformar uma sequência de quadros em localizações, identidades persistentes e trajetórias mensuráveis.

Esse processo apresenta dificuldades próprias do domínio. As cabeças dos espermatozoides ocupam poucos pixels, têm aparência semelhante e podem apresentar baixo contraste em relação ao fundo. O movimento é rápido e irregular, e cruzamentos, sobreposições, detritos, variações de iluminação e deriva da câmera podem produzir detecções incorretas ou trocas de identidade. No cenário específico deste trabalho, há ainda uma contracorrente gerada por um tubo. A influência visual desse movimento precisa ser separada, tanto quanto possível, do deslocamento individual das células. Por isso, a proposta articula detecção, rastreamento multiobjeto, fluxo óptico e predição temporal em uma pipeline modular.

1.1 Motivação

A infertilidade constitui um problema de saúde pública com repercussões pessoais e sociais. A Organização Mundial da Saúde estima que aproximadamente uma em cada seis pessoas adultas vivencie infertilidade ao longo da vida (World Health Organization, 2023). Como a motilidade espermática integra a avaliação da fertilidade masculina, métodos computacionais que contribuam para uma análise mais objetiva, reprodutível e escalável podem apoiar estudos laboratoriais e pesquisas em reprodução humana. O presente trabalho, contudo, não pretende realizar diagnóstico clínico; seu objeto é a avaliação computacional de trajetórias em vídeos microscópicos.

Do ponto de vista acadêmico, o problema reúne desafios clássicos e atuais de Visão Computacional: detecção de objetos pequenos, associação temporal, manutenção de identificadores, estimação de movimento e modelagem de sequências. O conjunto VISEM reuniu vídeos microscópicos e dados de análise seminal de 85 participantes (HAUGEN et al., 2019). Posteriormente, o VISEM-Tracking disponibilizou caixas delimitadoras, classes e identificadores persistentes em 20 vídeos, viabilizando avaliações sistemáticas de detecção e Rastreamento Multiobjeto (MOT) (THAMBAWITA et al., 2023). Esses recursos permitem construir referências experimentais antes de transferir a pipeline para os vídeos do cenário-alvo.

Os trabalhos existentes demonstram avanços em partes do problema. O *motilitAI* emprega fluxo óptico e aprendizado de máquina para estimar proporções agregadas de classes de motilidade (OTTIL et al., 2022); Noy et al. (NOY et al., 2023) utilizam redes recorrentes para prever posições futuras a partir de trajetórias previamente obtidas; e Zhang et al. (ZHANG et al., 2024) combinam um detector especializado com rastreamento para o VISEM-Tracking. Permanece, entretanto, a oportunidade de avaliar de forma controlada se o movimento aparente estimado no entorno de cada célula acrescenta informação útil à predição individual, além do histórico de posições e velocidades.

1.2 Problema

O problema de pesquisa consiste em determinar se uma pipeline computacional consegue detectar e rastrear múltiplos espermatozoides em vídeos microscópicos e se características locais de fluxo óptico contribuem para prever suas posições futuras. A questão envolve dois níveis de dificuldade. No primeiro, erros do detector e do rastreador afetam a continuidade das trajetórias. No segundo, mesmo uma trajetória corretamente observada pode mudar de direção ou velocidade de modo que modelos cinemáticos simples deixem de representar sua dinâmica.

O fluxo óptico oferece uma descrição do deslocamento aparente de padrões de intensidade entre quadros, mas não corresponde automaticamente à velocidade física do fluido. Nos dados considerados, o campo observado pode misturar movimento das células, estruturas do meio, artefatos e movimento da câmera. Além disso, não há uma medição física de referência do escoamento. Assim, o trabalho precisa avaliar a utilidade computacional desse campo sem atribuir a ele uma interpretação física que os dados não sustentem.

A delimitação adotada concentra-se na localização bidimensional das cabeças dos espermatozoides e na predição de suas coordenadas em horizontes curtos. Morfologia detalhada, vitalidade, concentração seminal, diagnóstico médico e modelagem física completa do escoamento não fazem parte do escopo. Essa delimitação permite avaliar cada módulo com critérios objetivos e relacionar os resultados à hipótese de pesquisa.

1.3 Hipótese

A hipótese principal é que a inclusão de características locais de fluxo óptico, associadas ao histórico de posições de cada espermatozoide, reduz o erro de predição de posições futuras em comparação com modelos equivalentes que utilizam somente posição e velocidade. A verificação será feita por uma ablação pareada: serão mantidos os mesmos dados, divisões, horizontes, arquiteturas e hiperparâmetros, alterando-se apenas a presença das características de fluxo.

Três perguntas orientam a investigação:

1. Qual combinação de detector e rastreador preserva melhor as identidades dos espermatozoides nas sequências avaliadas?
2. O campo de movimento aparente apresenta consistência temporal suficiente para ser utilizado como atributo de predição?
3. A inclusão desse campo reduz os erros de predição e em quais condições de densidade celular, duração de trajetória e horizonte temporal esse efeito ocorre?

1.4 Objetivos

1.4.1 Objetivo geral

Investigar, implementar e avaliar uma pipeline computacional para análise e predição de trajetórias de espermatozoides em vídeos microscópicos, combinando técnicas de detecção, rastreamento multiobjeto e fluxo óptico, com ênfase na avaliação do efeito do movimento aparente sobre a previsão de posições futuras.

1.4.2 Objetivos específicos

1. organizar os vídeos, metadados e anotações em divisões experimentais independentes e reproduzíveis;
2. implementar e comparar abordagens clássicas e aprendidas para detectar espermatozoides;
3. implementar e avaliar métodos de associação temporal capazes de manter identificadores persistentes;
4. extrair trajetórias e calcular medidas cinemáticas compatíveis com a calibração disponível;
5. estimar e analisar o campo de movimento aparente entre quadros, compensando movimento global quando necessário;

6. comparar preditores de trajetórias com e sem características derivadas do fluxo óptico; e
7. analisar quantitativa e qualitativamente os resultados, identificando limitações e condições de sucesso ou falha.

1.5 Contribuições esperadas

A principal contribuição esperada é uma avaliação controlada da utilidade de características de fluxo óptico para a predição individual de trajetórias de espermatozoides. A comparação será feita tanto sobre trajetórias anotadas, isolando o preditor, quanto sobre trajetórias produzidas pela pipeline, permitindo medir a propagação dos erros de detecção e rastreamento.

Também se espera produzir uma organização reprodutível dos dados, linhas de base clássicas e modernas para cada módulo e uma análise das limitações envolvidas na transferência de métodos de Visão Computacional para vídeos microscópicos. O código, os modelos e os arquivos de resultados constituirão artefatos necessários aos experimentos, mas a contribuição científica será a evidência obtida sob critérios comuns de avaliação.

1.6 Organização da Monografia

Além desta introdução, a monografia está organizada em quatro capítulos. O Capítulo 2 apresenta os conceitos de análise seminal assistida por computador, processamento de imagens, detecção, rastreamento multiobjeto, fluxo óptico, predição de trajetórias, conjuntos de dados e métricas. O Capítulo 3 analisa os trabalhos relacionados e explicita a lacuna investigada. O Capítulo 4 descreve os dados, os módulos da pipeline, os experimentos e os critérios de validação. Por fim, o Capítulo 5 registra as alterações realizadas para consolidar as entregas anteriores e apresenta as expectativas para a continuidade do trabalho.

Fundamentação Teórica

Este capítulo apresenta os conceitos necessários para compreender a análise e a predição de trajetórias de espermatozoides em vídeos microscópicos. A organização acompanha o fluxo dos dados na pipeline: o domínio de aplicação define as medidas de interesse; o processamento de imagens permite localizar as células; o rastreamento associa observações ao longo do tempo; o fluxo óptico descreve movimento aparente; e a predição estima posições ainda não observadas. Ao final, são apresentados os conjuntos de dados e as métricas que permitem avaliar cada módulo separadamente.

2.1 Análise seminal assistida por computador

A análise seminal examina características do sêmen e dos espermatozoides, entre elas concentração, contagem total, morfologia, vitalidade e motilidade. A sexta edição do manual da Organização Mundial da Saúde sistematiza procedimentos de laboratório e ressalta a importância do controle de qualidade para produzir resultados comparáveis (World Health Organization, 2021). Na avaliação básica, a motilidade pode ser classificada como progressiva, não progressiva ou imóvel.

Sistemas CASA combinam microscopia, aquisição digital de vídeo e algoritmos para tornar essa avaliação quantitativa. Em vez de resumir a amostra somente pela inspeção visual, esses sistemas localizam cabeças de espermatozoides, associam observações da mesma célula e calculam grandezas cinemáticas a partir das coordenadas registradas no tempo. A automação, entretanto, não elimina a necessidade de padronização: taxa de quadros, ampliação, profundidade da câmara, contraste e regras de classificação influenciam diretamente os valores obtidos.

Considere uma trajetória bidimensional formada pelas posições $\mathbf{p}_t = (x_t, y_t)$, observadas em intervalos constantes Δt . Para uma trajetória com T posições, a velocidade curvilínea, velocidade curvilínea (VCL), corresponde ao comprimento acumulado do caminho dividido pelo tempo, enquanto a velocidade em linha reta, velocidade em linha reta (VSL), considera apenas a distância entre a primeira e a última posição:

$$\text{VCL} = \frac{\sum_{t=1}^{T-1} \|\mathbf{p}_{t+1} - \mathbf{p}_t\|_2}{(T-1)\Delta t}, \quad (1)$$

$$\text{VSL} = \frac{\|\mathbf{p}_T - \mathbf{p}_1\|_2}{(T-1)\Delta t}. \quad (2)$$

A velocidade do percurso médio, velocidade do percurso médio (VAP), é calculada ao longo de uma versão suavizada da trajetória. A linearidade, linearidade (LIN), compara o deslocamento líquido com o caminho curvilíneo e pode ser expressa por $\text{LIN} = 100 \text{ VSL} / \text{VCL}$ (World Health Organization, 2021). Para que as velocidades sejam apresentadas em $\mu\text{m/s}$, é necessário conhecer a escala espacial e a taxa de quadros. Sem essa calibração, as medidas devem permanecer em pixels por unidade de tempo.

2.2 Processamento de imagens e detecção

Uma imagem digital pode ser representada por uma função discreta de intensidade ou por múltiplos canais de cor. Em vídeos microscópicos, o processamento inicial busca aumentar a separação entre as cabeças dos espermatozoides e o fundo. Conversão para tons de cinza, redução de ruído, normalização de contraste, limiarização e operações morfológicas são transformações comuns nessa etapa (SZELISKI, 2022).

A segmentação por limiar divide os pixels de acordo com sua intensidade. O método de Otsu seleciona automaticamente um limiar que maximiza a separação estatística entre classes do histograma (OTSU, 1979). Após a binarização, erosão e dilatação podem remover componentes pequenos, preencher falhas ou separar estruturas segundo o elemento estruturante. Quando objetos próximos formam uma única região, a transformação *watershed* oferece uma alternativa baseada em marcadores. Esses métodos são rápidos e interpretáveis, mas seus parâmetros são sensíveis a mudanças de contraste, iluminação, densidade celular e presença de detritos.

Na detecção de objetos, a saída contém, para cada instância, uma classe, uma caixa delimitadora e uma confiança. A família YOLO consolidou detectores de um estágio que realizam localização e classificação em uma única rede neural (REDMON et al., 2016). O VISEM-Tracking utiliza coordenadas normalizadas em formato compatível com YOLO e oferece classes para espermatozoides, aglomerados e células pequenas ou com cabeça reduzida (THAMBAWITA et al., 2023).

A detecção de espermatozoides é um caso de detecção de objetos pequenos: poucos pixels descrevem cada cabeça, a textura individual é limitada e o borramento de movimento reduz a nitidez. Por isso, abordagens recentes utilizam resoluções maiores, camadas dedicadas a objetos pequenos e mecanismos de atenção. Zhang et al. (ZHANG et al., 2024), por exemplo, adaptam o YOLOv8 e um rastreador para o domínio espermático.

A avaliação precisa considerar precisão, revocação, qualidade de localização e tempo de execução, pois os erros do detector são propagados para o rastreamento.

2.3 Rastreamento multiobjeto

O MOT consiste em estimar simultaneamente o estado de vários objetos e manter um identificador consistente para cada um ao longo do vídeo. Na estratégia *tracking-by-detection*, cada quadro é processado por um detector e as novas observações são associadas às trajetórias existentes. O estado pode incluir posição, tamanho da caixa e velocidade. Uma trajetória é iniciada quando uma detecção persiste, atualizada enquanto recebe observações compatíveis e encerrada após permanecer ausente por um número definido de quadros.

Dois fundamentos desse processo são a estimação de estado e a associação de dados. O Filtro de Kalman representa a evolução do estado por um modelo linear com incerteza: primeiro prediz o estado no novo instante e depois corrige a previsão com a medição observada, ponderando as covariâncias dos ruídos de processo e de medição (KALMAN, 1960). Para associar trajetórias e detecções, constrói-se uma matriz de custos com distâncias entre centroides, sobreposição entre caixas ou outra medida de similaridade. O algoritmo Húngaro fornece uma atribuição global de custo mínimo sob correspondências um a um.

O SORT combina Filtro de Kalman, sobreposição entre caixas e associação Húngara em um rastreador simples e rápido (BEWLEY et al., 2016). O ByteTrack, por sua vez, realiza associações sucessivas com detecções de alta e baixa confiança, buscando recuperar objetos que seriam descartados por um limiar único (ZHANG et al., 2022). Esses métodos mostram a evolução de modelos baseados principalmente em movimento para estratégias que combinam localização, confiança e, em alguns casos, aparência.

No domínio espermático, a associação é dificultada pela alta densidade, pelas trajetórias rápidas e curvas e pela semelhança visual entre indivíduos. Descritores de reidentificação podem ser pouco discriminativos quando as cabeças ocupam poucos pixels; por outro lado, utilizar somente distância espacial falha em cruzamentos e mudanças bruscas de direção. As identidades manuais do VISEM-Tracking permitem medir trocas de identidade, fragmentações e recuperação após ausências (THAMBAWITA et al., 2023).

2.4 Fluxo óptico e movimento aparente

Fluxo óptico é um campo vetorial que descreve o deslocamento aparente de padrões de intensidade entre quadros. Para cada posição (x, y) , procura-se um vetor $\mathbf{v}(x, y) = (u, v)$ que relacione a imagem no instante atual à imagem seguinte. Sob a hipótese de constância de brilho,

$$I(x, y, t) = I(x + u\Delta t, y + v\Delta t, t + \Delta t), \quad (3)$$

uma aproximação de primeira ordem produz a equação de restrição

$$I_x u + I_y v + I_t = 0. \quad (4)$$

Há uma equação para duas incógnitas, portanto são necessárias restrições adicionais. Métodos locais, como Lucas–Kanade, supõem movimento aproximadamente constante em uma vizinhança. Formulações globais, como Horn–Schunck, introduzem suavidade no campo. Farneback aproxima vizinhanças por polinômios e estima fluxo denso em múltiplas escalas, constituindo uma linha de base prática para vídeos (FARNEBÄCK, 2003; SZELISKI, 2022).

Abordagens aprendidas estimam correspondências a partir de bases com deslocamento conhecido. O RAFT constrói volumes de correlação entre características dos dois quadros e atualiza iterativamente o campo por uma unidade recorrente (TEED; DENG, 2020). Embora apresente bons resultados em conjuntos gerais de fluxo óptico, sua transferência para microscopia precisa ser avaliada, pois escala, textura, contraste e formação da imagem diferem das cenas de treinamento.

Neste trabalho, o fluxo possui dois usos potenciais: compensar movimento global da imagem e produzir características locais para a predição. É necessário distinguir esse campo da velocidade física do fluido. O fluxo óptico é medido em coordenadas de imagem e pode misturar deslocamento das células, do meio visível, de artefatos e da câmera. Como os conjuntos utilizados não fornecem uma medição física de referência do escoamento, o resultado será denominado campo de movimento aparente.

2.5 Predição de trajetórias

Predição de trajetória consiste em estimar posições futuras a partir de uma sequência observada. Se $\mathbf{p}_{t-p+1:t}$ representa uma janela de p posições, o objetivo é produzir $\hat{\mathbf{p}}_{t+1:t+q}$ para um horizonte de q quadros. A tarefa difere do rastreamento: o rastreador estima o estado atual com medições já disponíveis, enquanto o preditor é avaliado em posições ocultas durante a inferência.

Modelos cinemáticos simples são referências importantes. A extrapolação de velocidade constante usa o deslocamento recente para projetar a posição, e o Filtro de Kalman acrescenta incertezas de processo e medição (KALMAN, 1960). Esses métodos são interpretáveis e exigem poucos dados, mas tendem a degradar quando a célula altera rapidamente sua direção ou velocidade.

Redes recorrentes representam dependências em sequências. A Memória de Longo e Curto Prazo (LSTM) utiliza células de memória e portas de controle para preservar

informação por intervalos mais longos (HOCHREITER; SCHMIDHUBER, 1997). Em predição de trajetórias, posições ou deslocamentos sucessivos são codificados em um estado oculto, a partir do qual são geradas coordenadas futuras. O Social LSTM mostrou como essa formulação pode ser aplicada a trajetórias de agentes (ALAHY et al., 2016); no domínio deste trabalho, Noy et al. (NOY et al., 2023) aplicaram LSTM à localização futura de espermatozoides.

A hipótese computacional desta pesquisa considera que o histórico geométrico pode ser complementado por movimento aparente. Um modelo sem fluxo pode receber $(x, y, \Delta x, \Delta y)$, enquanto o modelo com fluxo acrescenta $(u, v, \|\mathbf{v}\|, \theta)$ amostrados na vizinhança da célula. A comparação deve manter arquitetura, histórico, horizonte e divisão dos dados controlados, alterando somente as características de fluxo.

2.6 Conjuntos de dados

O VISEM contém 85 vídeos microscópicos associados a resultados de análise seminal e atributos biológicos, mas não fornece identificadores de rastreamento quadro a quadro (HAUGEN et al., 2019). O VISEM-Tracking seleciona 20 vídeos de 30 segundos, totalizando 29.196 quadros, e acrescenta caixas delimitadoras, classes e identificadores persistentes verificados por especialistas (THAMBAWITA et al., 2023). Por isso, o segundo conjunto é adequado ao treinamento e à avaliação de detecção, rastreamento e predição baseada em trajetórias anotadas.

Os vídeos do cenário-alvo contêm a contracorrente gerada por um tubo e serão utilizados para avaliar a transferência da pipeline ao domínio específico do TCC. As divisões de treinamento, validação e teste deverão ser feitas por vídeo, participante ou unidade de aquisição, nunca por quadros aleatórios. Essa precaução impede que imagens quase idênticas da mesma sequência apareçam simultaneamente no treinamento e no teste.

2.7 Métricas de avaliação

Na detecção, precisão e revocação são definidas a partir de verdadeiros positivos (VP), falsos positivos (FP) e falsos negativos (FN):

$$\text{Precisão} = \frac{\text{VP}}{\text{VP} + \text{FP}}, \quad \text{Revocação} = \frac{\text{VP}}{\text{VP} + \text{FN}}. \quad (5)$$

Uma detecção é considerada correspondente ao gabarito quando a Interseção sobre União (IoU) ultrapassa um limiar. A área sob a curva de precisão–revocação gera a precisão média, e a média entre classes ou limiares gera a precisão média (mAP). Como poucos pixels de deslocamento afetam significativamente a IoU de objetos pequenos, também é útil analisar erro de centroide e resultados por classe.

No rastreamento, a Acurácia de Rastreamento Multiobjeto (MOTA) combina falsos positivos, falsos negativos e trocas de identidade. A medida F1 de identificação (IDF1) mede a preservação de identidade por meio da média harmônica entre precisão e revocação no espaço das associações. A Acurácia de Rastreamento de Ordem Superior (HOTA) foi proposta para equilibrar qualidade de detecção, associação e localização (LUITEN et al., 2021). Neste trabalho, HOTA será a métrica principal de rastreamento, acompanhada por MOTA, IDF1, trocas de identidade, fragmentações e tempo por quadro.

Na predição, o Erro Médio de Deslocamento (ADE) resume o erro ao longo de todo o horizonte, enquanto o Erro de Deslocamento Final (FDE) considera a última posição prevista. Para N trajetórias e horizonte de q quadros:

$$\text{ADE} = \frac{1}{Nq} \sum_{i=1}^N \sum_{k=1}^q \|\hat{\mathbf{p}}_{i,t+k} - \mathbf{p}_{i,t+k}\|_2, \quad (6)$$

$$\text{FDE} = \frac{1}{N} \sum_{i=1}^N \|\hat{\mathbf{p}}_{i,t+q} - \mathbf{p}_{i,t+q}\|_2. \quad (7)$$

Essas medidas devem ser apresentadas no mesmo sistema de coordenadas e, quando houver calibração, também em unidade física (ALAHÍ et al., 2016). Médias serão acompanhadas por dispersão, intervalos de confiança e análise estratificada por horizonte, densidade celular e duração da trajetória.

Trabalhos Relacionados

Este capítulo analisa quatro trabalhos diretamente relacionados às etapas da pipeline proposta. Os estudos foram selecionados por abordarem motilidade espermática, disponibilização de trajetórias anotadas, predição de posições ou detecção e rastreamento no mesmo domínio. A comparação considera objetivo, dados, método, resultados e aspectos ainda não tratados em conjunto.

Ottl et al. (OTTTL et al., 2022) propõem o *motilitAI*, um arcabouço para estimar automaticamente as proporções de espermatozoides progressivos, não progressivos e imóveis em vídeos microscópicos. O método realiza pré-processamento dos vídeos do VISEM, rastreia células por uma adaptação esparsa do fluxo óptico de Lucas–Kanade, extrai descritores de movimento e aparência e utiliza modelos de regressão. A melhor configuração alcançou erro absoluto médio de 7,31 pontos percentuais, inferior aos 8,83 pontos do melhor resultado da competição de referência utilizada pelos autores. O estudo demonstra que movimento e trajetórias extraídos de vídeo fornecem informação sobre motilidade, porém sua saída é agregada para a amostra. O presente projeto, em contraste, pretende manter trajetórias individuais e prever posições futuras.

Thambawita et al. (THAMBAWITA et al., 2023) apresentam o VISEM-Tracking, criado para reduzir a escassez de vídeos públicos com anotações temporais de espermatozoides humanos. O conjunto contém 20 vídeos de 30 segundos, totalizando 29.196 quadros, com caixas delimitadoras, identificadores persistentes e classes para espermatozoides, aglomerados e células pequenas ou com cabeça reduzida. Os autores também disponibilizam características seminais e sequências sem rótulos. Como validação técnica, foram treinadas variantes do YOLOv5, demonstrando que as anotações sustentam modelos supervisionados. A relação com este projeto é direta, pois os dados podem apoiar os módulos de detecção, rastreamento e predição. O artigo, contudo, não propõe um preditor nem estima movimento do meio.

Noy et al. (NOY et al., 2023) investigam a localização futura de espermatozoides para aplicações que exigem posicionamento rápido e não invasivo. Os autores combinam uma rede LSTM multicamadas, responsável por aprender a dinâmica não linear a partir

do histórico de posições, com extrapolação linear e uma função de perda ajustada ao problema. Os experimentos utilizam 501 trajetórias, com 114.229 quadros obtidos de três doadores a 70 quadros por segundo, e avaliam horizontes de até 1,43 segundo. Para horizontes inferiores a 0,6 segundo, o erro médio de localização permanece entre 4 e 8 μm ; em várias configurações, o modelo reduz o erro da extrapolação linear. O estudo constitui uma referência direta para a etapa de predição, mas parte de trajetórias previamente obtidas e não incorpora detecção multiobjeto ou características de fluxo óptico.

Zhang et al. (ZHANG et al., 2024) tratam conjuntamente a detecção e o rastreamento de espermatozoides com o método Sperm YOLOv8E-TrackEVD. O detector adapta o YOLOv8 com mecanismo de atenção, camada dedicada a objetos pequenos e módulos especializados. O rastreador modifica o DeepOCSORT para melhorar a associação temporal nesse domínio. No VISEM-Tracking, o sistema completo alcança HOTA de 74,303% e MOTA de 71,167%. O trabalho fornece uma referência para os módulos de detecção, associação e avaliação, mas não aborda a estimação de movimento aparente do meio nem a predição de posições futuras.

3.1 Comparação entre os trabalhos

A Tabela 1 sintetiza as diferenças entre os estudos. Em conjunto, eles fornecem dados, métodos e métricas para as partes centrais da proposta, mas nenhum avalia, em uma mesma pipeline, a influência de características locais de fluxo óptico sobre a predição individual após a detecção e o rastreamento.

Tabela 1 – Comparação dos trabalhos relacionados

Trabalho	Objetivo e dados	Método e resultado principal	Relação com este projeto
Ottl et al. (2022)	Estimar proporções de classes de motilidade em vídeos do VISEM	Fluxo óptico esperso, descritores e regressão; erro absoluto médio de 7,31 pontos percentuais	Utiliza movimento e rastreamento, mas produz apenas estimativas agregadas da amostra
Thambawita et al. (2023)	Disponibilizar vídeos, caixas e identidades de rastreamento	Anotação especializada de 20 vídeos e linhas de base com YOLOv5	Fornecer dados para detecção, rastreamento e avaliação de trajetórias
Noy et al. (2023)	Prever posições futuras em 501 trajetórias	LSTM combinada à extrapolação linear; erro de 4 a 8 μ m em horizontes menores que 0,6 s	É referência de predição, mas não inclui detecção, MOT ou características de fluxo
Zhang et al. (2024)	Detectar e rastrear no VISEM-Tracking	YOLOv8 aprimorado e DeepOCSORT modificado; HOTA de 74,303% e MOTA de 71,167%	É referência para detecção e associação, sem prever trajetórias futuras

Fonte: Elaborada pelo autor (2026).

3.2 Lacuna investigada

Os estudos analisados evidenciam três lacunas complementares. Primeiro, trabalhos de análise de motilidade podem utilizar trajetórias e fluxo óptico sem preservar uma previsão individual de cada célula. Segundo, conjuntos e métodos de rastreamento fornecem identidades persistentes, mas encerram a análise no estado observado. Terceiro, modelos de predição partem de trajetórias prontas e não medem como erros da pipeline afetam o horizonte futuro.

O presente trabalho procura conectar essas etapas por meio de uma arquitetura modular. A contribuição não consiste apenas em encadear algoritmos, mas em comparar, sob os mesmos dados e critérios, preditores com e sem características de movimento aparente. A avaliação separada sobre trajetórias anotadas e trajetórias estimadas permitirá distinguir a capacidade do preditor da degradação introduzida por detecção e rastreamento.

CAPÍTULO 4

Método

O trabalho será conduzido como uma pesquisa aplicada, quantitativa e experimental em Visão Computacional. O método consiste na implementação e na avaliação controlada de uma pipeline para detecção, rastreamento multiobjeto, estimação de movimento aparente e predição de trajetórias de espermatozoides em vídeos microscópicos. A hipótese será examinada por experimentos reproduzíveis que comparem modelos equivalentes com e sem características locais de fluxo óptico.

4.1 Produtos e dados da pesquisa

Os produtos derivados serão uma coleção de dados organizada com divisões experimentais documentadas; uma pipeline modular em Python; modelos treinados; arquivos contendo caixas, identificadores, trajetórias e campos vetoriais; e uma análise comparativa apresentada por métricas, tabelas e visualizações. O código e os modelos serão artefatos necessários à realização dos experimentos, enquanto o produto científico principal será a evidência sobre o efeito do fluxo óptico na predição de trajetórias.

O VISEM-Tracking será empregado no treinamento e na avaliação inicial dos módulos supervisionados (THAMBAWITA et al., 2023). Os vídeos com contracorrente gerada por tubo serão utilizados para avaliar a pipeline no cenário específico do TCC. Caso não apresentem anotações completas, será selecionado um subconjunto representativo de trechos para anotação de caixas e identidades, com verificação de consistência temporal.

4.2 Levantamento, geração e organização dos dados

Para cada vídeo serão registrados resolução, taxa de quadros, duração, escala espacial quando disponível e condições de aquisição. Os quadros serão extraídos preservando a ordem temporal e vinculados a um identificador único. O pré-processamento será limitado a operações cuja influência possa ser controlada, como conversão de cor, normalização de intensidade, correção moderada de contraste e redução de ruído. As anotações serão

convertidas para uma representação comum, e as coordenadas das trajetórias serão obtidas a partir do centro das caixas.

Será adotada uma separação fixa em conjuntos de treinamento, validação e teste. O treinamento servirá para estimar os parâmetros dos modelos; a validação, para escolher hiperparâmetros e critérios de parada; e o teste permanecerá isolado até a definição final. As divisões serão realizadas por vídeo ou unidade de aquisição, evitando que quadros ou trechos da mesma origem sejam distribuídos entre conjuntos diferentes. Arquivos de configuração registrarão divisões, sementes aleatórias, versões das bibliotecas e parâmetros experimentais.

4.3 Detecção e rastreamento multiobjeto

A detecção será iniciada com uma linha de base clássica baseada em limiarização, operações morfológicas e componentes conexos. Em seguida, será treinado um detector da família YOLO com as anotações do VISEM-Tracking. A comparação permitirá medir a contribuição do aprendizado supervisionado em cenas de baixo contraste, alta densidade e objetos pequenos. Serão registradas precisão, revocação, $\text{mAP}@0,5$, $\text{mAP}@0,5:0,95$ e tempo médio por quadro. O método de Zhang et al. (ZHANG et al., 2024) será utilizado como referência do domínio, considerando as diferenças de dados e ambiente computacional.

As detecções serão associadas temporalmente por métodos de complexidade crescente. O primeiro será um rastreador por proximidade entre centroides; o segundo, o SORT, que combina Filtro de Kalman e associação Húngara (BEWLEY et al., 2016); e o terceiro, o ByteTrack, que aproveita detecções de diferentes níveis de confiança (ZHANG et al., 2022). Limiares de associação e o número de quadros tolerados sem detecção serão escolhidos na validação. As saídas terão a forma (v, t, i, x, y) , em que v identifica o vídeo, t o quadro, i a célula e (x, y) a posição de seu centro.

4.4 Estimação do movimento aparente

O fluxo óptico denso será estimado inicialmente por Farnebäck, escolhido como linha de base por seu custo moderado e disponibilidade no OpenCV (FARNEBÄCK, 2003). Se os recursos computacionais permitirem, o RAFT será incluído como alternativa baseada em aprendizado profundo (TEED; DENG, 2020). Movimentos globais da câmera serão estimados e compensados quando detectados. Regiões ocupadas pelas células e por artefatos evidentes serão mascaradas para reduzir sua influência; os vetores restantes serão agregados de forma robusta e suavizados no espaço e no tempo.

Como os conjuntos considerados não fornecem uma medição física do campo de velocidade do fluido, o resultado será tratado como campo de movimento aparente. Sua

consistência será analisada por erro fotométrico após a deformação de um quadro em direção ao seguinte, concordância entre fluxos direto e reverso, regularidade temporal e estabilidade nas regiões de fundo. Sequências sintéticas com deslocamentos conhecidos poderão complementar a avaliação. A conversão para unidades físicas somente será realizada quando houver calibração espacial e temporal confiável.

4.5 Predição das trajetórias

Cada trajetória válida será dividida em uma janela observada de p quadros e um horizonte futuro de q quadros. As entradas básicas serão posição, deslocamento e velocidade estimada. As configurações com fluxo acrescentarão o vetor aparente amostrado na posição da célula e estatísticas de uma vizinhança local. Serão comparados um modelo de velocidade constante baseado no Filtro de Kalman, uma rede LSTM e, se houver ganho justificável, uma Unidade Recorrente Fechada (GRU). A LSTM foi escolhida por representar dependências temporais e já ter sido aplicada à previsão da localização de espermatozoides (NOY et al., 2023).

O experimento principal será uma ablação pareada. O mesmo preditor, com os mesmos dados, janelas, hiperparâmetros e sementes, será treinado primeiro sem fluxo e depois com características de fluxo. A variável controlada será, portanto, a presença do movimento aparente, e não uma mudança simultânea de arquitetura. A avaliação ocorrerá em dois cenários: trajetórias anotadas, para isolar o preditor, e trajetórias produzidas pelo rastreador, para medir a degradação da pipeline completa.

4.6 Critérios de validação e comparação

Na detecção serão utilizadas precisão, revocação e mAP. No rastreamento, a métrica principal será HOTA, acompanhada por MOTA, IDF1, trocas de identidade e fragmentações (LUITEN et al., 2021). Na predição serão calculados ADE e FDE (ALAHY et al., 2016). Os erros serão expressos em pixels normalizados e, quando houver calibração, também em micrômetros.

As comparações abrangerão linhas de base clássicas e métodos modernos, preditores sem e com fluxo e trajetórias anotadas e estimadas. Para evitar que vídeos longos dominem a média, os resultados serão agregados primeiro por trajetória e depois por vídeo. Serão informados média, mediana, desvio-padrão e intervalo de confiança de 95% obtido por reamostragem dos vídeos. Treinamentos estocásticos serão repetidos com sementes distintas.

Os resultados de detecção e rastreamento no VISEM-Tracking serão confrontados com os protocolos publicados por Thambawita et al. (THAMBAWITA et al., 2023) e Zhang et al. (ZHANG et al., 2024). A predição será comparada à linha de base de velocidade

constante e ao uso de LSTM descrito por Noy et al. (NOY et al., 2023). Diferenças de divisão dos dados, resolução, horizonte, hardware e implementação serão explicitadas para evitar comparações diretas entre condições incompatíveis.

4.7 Etapas de desenvolvimento

1. **Auditoria e padronização dos dados.** Os vídeos, metadados e anotações serão inventariados, convertidos para formatos comuns e verificados visualmente.
2. **Definição das divisões e linhas de base.** Serão fixados os conjuntos de treinamento, validação e teste, as sementes e as configurações clássicas de referência.
3. **Treinamento e avaliação da detecção.** A abordagem clássica e o detector aprendido serão ajustados e comparados sob os mesmos dados.
4. **Implementação do rastreamento.** Os métodos por centroide, SORT e ByteTrack serão aplicados às mesmas detecções para separar falhas de localização e associação.
5. **Estimação e análise do fluxo.** Farnebäck e, se viável, RAFT serão executados com compensação de movimento global e máscaras de primeiro plano.
6. **Construção dos conjuntos de predição.** As trajetórias serão filtradas, normalizadas e convertidas em pares de janelas observadas e futuras.
7. **Treinamento e ablação dos preditores.** As configurações com e sem fluxo serão avaliadas nos cenários controlados.
8. **Análise e documentação.** Os resultados serão agregados, acompanhados por intervalos de confiança, visualizações e exemplos de falha, e relacionados à hipótese de pesquisa.

4.8 Declaração sobre o uso de Inteligência Artificial

Para a consolidação desta versão inicial, utilizei as ferramentas ChatGPT e Codex, da OpenAI, como apoio à organização dos conteúdos das entregas anteriores, à pesquisa bibliográfica, à revisão linguística, à conferência da coerência entre os capítulos e à formatação em LaTeX. O tema, os objetivos, as decisões metodológicas e a revisão final do texto são de minha responsabilidade, e a submissão será realizada após a concordância do orientador.

Conclusão

Esta versão inicial consolidou as quatro entregas anteriores na estrutura do modelo de monografia da Faculdade de Computação. O conteúdo da E1 foi reorganizado na Introdução, com separação explícita entre motivação, problema, hipótese, objetivos e contribuições esperadas. Essa mudança eliminou a organização por parágrafos do enunciado e tornou mais clara a relação entre a relevância do tema, a questão investigada e os critérios necessários para verificar o objetivo.

A fundamentação da E2 foi revisada para apresentar os conceitos na ordem em que são utilizados pela pipeline: análise seminal assistida por computador, detecção, rastreamento, fluxo óptico, predição, dados e métricas. Os textos de caráter didático solicitados exclusivamente nas entregas anteriores foram removidos. Os trabalhos analisados na E3 passaram a compor um capítulo próprio, sem os resumos de capítulos do livro e sem informações conjunturais que não contribuem diretamente para a comparação científica. A tabela comparativa foi mantida e atualizada para evidenciar a lacuna relacionada à integração entre rastreamento, movimento aparente e predição individual.

O método proveniente da E4 foi ajustado para manter correspondência direta com a hipótese. Foram detalhadas as divisões dos dados, as linhas de base, a ablação com e sem fluxo, os cenários com trajetórias anotadas e estimadas e os critérios de avaliação. Essa revisão busca reduzir ambiguidades, evitar vazamento de informação e distinguir o movimento aparente medido na imagem de uma velocidade física do fluido. A declaração sobre o uso de Inteligência Artificial foi mantida somente no capítulo de Método, conforme solicitado para esta entrega.

5.1 Expectativas para a continuidade

As próximas etapas consistem em auditar os vídeos e as anotações, definir as divisões experimentais e implementar as linhas de base de detecção e rastreamento. Em seguida, serão avaliados os métodos de fluxo óptico e construídas as janelas de predição. A comparação pareada entre modelos com e sem características de fluxo deverá indicar se a

hipótese é sustentada e em quais condições o movimento aparente contribui para reduzir ADE e FDE.

Espera-se que os resultados permitam identificar não apenas a melhor configuração média, mas também as situações em que cada módulo falha. A versão final deverá substituir esta descrição de expectativas por resultados experimentais, discussão das limitações, verificação dos objetivos e síntese das contribuições efetivamente obtidas.

Referências

- ALAHÍ, A. et al. Social LSTM: Human trajectory prediction in crowded spaces. In: **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition**. [s.n.], 2016. p. 961–971. Disponível em: <<https://doi.org/10.1109/CVPR.2016.110>>. Citado 3 vezes nas páginas 17, 18 e 24.
- BEWLEY, A. et al. Simple online and realtime tracking. In: **2016 IEEE International Conference on Image Processing**. [s.n.], 2016. p. 3464–3468. Disponível em: <<https://doi.org/10.1109/ICIP.2016.7533003>>. Citado 2 vezes nas páginas 15 e 23.
- FARNEBÄCK, G. Two-frame motion estimation based on polynomial expansion. In: **Scandinavian Conference on Image Analysis**. Berlin: Springer, 2003. (Lecture Notes in Computer Science, v. 2749), p. 363–370. Disponível em: <https://doi.org/10.1007/3-540-45103-X_50>. Citado 2 vezes nas páginas 16 e 23.
- HAUGEN, T. B. et al. Visem: A multimodal video dataset of human spermatozoa. In: **Proceedings of the 10th ACM Multimedia Systems Conference**. New York: Association for Computing Machinery, 2019. p. 261–266. Disponível em: <<https://doi.org/10.1145/3304109.3325814>>. Citado 2 vezes nas páginas 10 e 17.
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural Computation**, v. 9, n. 8, p. 1735–1780, 1997. Disponível em: <<https://doi.org/10.1162/neco.1997.9.8.1735>>. Citado na página 17.
- KALMAN, R. E. A new approach to linear filtering and prediction problems. **Journal of Basic Engineering**, v. 82, n. 1, p. 35–45, 1960. Disponível em: <<https://doi.org/10.1115/1.3662552>>. Citado 2 vezes nas páginas 15 e 16.
- LUITEN, J. et al. HOTA: A higher order metric for evaluating multi-object tracking. **International Journal of Computer Vision**, v. 129, n. 2, p. 548–578, 2021. Disponível em: <<https://doi.org/10.1007/s11263-020-01375-2>>. Citado 2 vezes nas páginas 18 e 24.
- NOY, L. et al. Location prediction of sperm cells using long short-term memory networks. **Advanced Intelligent Systems**, Wiley, v. 5, n. 9, p. 2300161, 2023. Disponível em: <<https://doi.org/10.1002/aisy.202300161>>. Citado 5 vezes nas páginas 10, 17, 19, 24 e 25.

OTSU, N. A threshold selection method from gray-level histograms. **IEEE Transactions on Systems, Man, and Cybernetics**, v. 9, n. 1, p. 62–66, 1979. Disponível em: <<https://doi.org/10.1109/TSMC.1979.4310076>>. Citado na página 14.

OTTL, S. et al. motilitai: A machine learning framework for automatic prediction of human sperm motility. **iScience**, Elsevier, v. 25, n. 8, p. 104644, 2022. Disponível em: <<https://doi.org/10.1016/j.isci.2022.104644>>. Citado 2 vezes nas páginas 10 e 19.

REDMON, J. et al. You only look once: Unified, real-time object detection. In: **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition**. [s.n.], 2016. p. 779–788. Disponível em: <<https://doi.org/10.1109/CVPR.2016.91>>. Citado na página 14.

SZELISKI, R. **Computer Vision: Algorithms and Applications**. 2. ed. Cham: Springer, 2022. Disponível em: <<https://doi.org/10.1007/978-3-030-34372-9>>. Citado 2 vezes nas páginas 14 e 16.

TEED, Z.; DENG, J. RAFT: Recurrent all-pairs field transforms for optical flow. In: **Computer Vision – ECCV 2020**. Cham: Springer, 2020. (Lecture Notes in Computer Science, v. 12347), p. 402–419. Disponível em: <https://doi.org/10.1007/978-3-030-58536-5_24>. Citado 2 vezes nas páginas 16 e 23.

THAMBAWITA, V. et al. VISEM-Tracking, a human spermatozoa tracking dataset. **Scientific Data**, v. 10, n. 1, p. 260, 2023. Disponível em: <<https://doi.org/10.1038/s41597-023-02173-4>>. Citado 7 vezes nas páginas 10, 14, 15, 17, 19, 22 e 24.

World Health Organization. **WHO Laboratory Manual for the Examination and Processing of Human Semen**. 6. ed. Geneva: World Health Organization, 2021. ISBN 978-92-4-003078-7. Disponível em: <<https://www.who.int/publications/i/item/9789240030787>>. Acesso em: 27 jul. 2026. Citado 2 vezes nas páginas 13 e 14.

_____. **1 in 6 People Globally Affected by Infertility**. 2023. Disponível em: <<https://www.who.int/news/item/04-04-2023-1-in-6-people-globally-affected-by-infertility>>. Acesso em: 27 jul. 2026. Citado na página 9.

ZHANG, C. et al. Sperm YOLOv8E-TrackEVD: A novel approach for sperm detection and tracking. **Sensors**, MDPI, v. 24, n. 11, p. 3493, 2024. Disponível em: <<https://doi.org/10.3390/s24113493>>. Citado 5 vezes nas páginas 10, 14, 20, 23 e 24.

ZHANG, Y. et al. ByteTrack: Multi-object tracking by associating every detection box. In: **Computer Vision – ECCV 2022**. Cham: Springer, 2022. (Lecture Notes in Computer Science, v. 13682), p. 1–21. Disponível em: <https://doi.org/10.1007/978-3-031-20047-2_1>. Citado 2 vezes nas páginas 15 e 23.